

2023.08

Saltlux

Airflow 소개

- 2014년 에어비앤비에서 만든 워크플로우 관리 솔루션

— 2019년 아파치 Top Level(최상위) 프로젝트로 승격

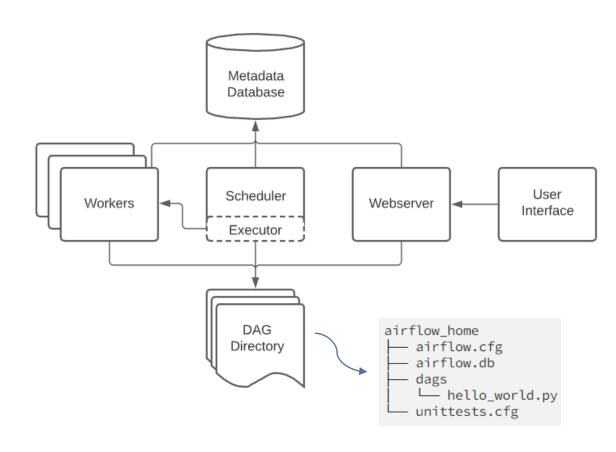
파이썬을 이용해 워크플로우를 만들고 관리할 수 있는오픈소스 기반 워크플로우 관리 도구

— ETL 작성 및 모니터링 같은 워크플로우 관리에 유용

Airflow 특징

- 파이썬으로 제작된 도구이며, 파이썬으로 워크플로우 생성
- 하나의 워크플로우는 DAG(Directed Acyclic Graph)이라 부르며, DAG은 1개 이상의 TASK가 존재
- TASK간 선후행 연결이 가능하지만, 순환되지 않고 방향성을 가짐
- Cron 기반의 스케줄링
- 모니터링 및 실패 작업에 대한 재실행 기능이 간편

Airflow 구조



✓ Scheduler

- Airflow의 DAG과 작업들을 모니터링하고 실행 순서와 상태 관리

✓ Worker

- Airflow의 작업을 실행하는 공간

✓ Metadata Database

- Airflow에서 실행할 작업에 관한 정보들을 저장

✓ Webserver

- Airflow의 User Interface 제공

✓ DAG Directory

- Airflow에서 실행할 작업들을 파이프라인 형태로 저장



Airflow는 Scheduler가 DAG Directory의 작업을 가져와서 Worker에서 실행하는 프로세스

Airflow 장/단점

- ✔ 파이썬이 익숙하다면 러닝 커브 빠르게 극복 가능
- ✔ 파이썬에서 지원되는 라이브러리 활용하여 다양한 도구 컨트롤 가능
- ✔ Airflow에서 제공하는 기능을 원하는 작업에 맞게 커스터마이징 가능

- ✔ real-time 워크플로우는 지원하지 않음 (최소 분 단위)
- ✔ 워크플로우를 GUI환경에서 만드는 것이 아니기 때문에, 파이썬 역량에 따라 작업 속도 차이가 큰 편
- ✓ 설계된 워크플로우가 많을 경우 DAG 관리를 위한 표준 없으면 망함

Airflow 설치

<별첨>

Airflow 오퍼레이터

SimpleHttpOperator

PythonOperator

BashOperator

BranchPythonOperator

EmailOperator

MySqlOperator

SqliteOperator

OracleOperator

coperator

PostgresOperator

MySqlOperator

JdbcOperator

Sensor

operator 특정 행위를 할 수 있는 기능을 모아놓은 클래스

task 오퍼레이터에서 객체화되어 DAG에서 실행 가능한 객체

* 워크플로우 = DAG

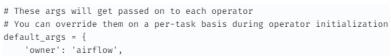
DAG

└ Operator → Task

Airflow 샘플

```
INIT DAG
dag id = 'exam01-db2db'
default args = {
    'owner': 'aaron',
    'start date': datetime(2023, 8, 4, tzinfo=KST),
   #'retry delay': timedelta(minutes=5),
    'catchup': False,
# CREATE DAG
dag = DAG(dag id=dag id,
          default_args=default_args,
          schedule interval='@once',
          tags=['pythonOperator', 'oracleHook', 'example'],
t_start = DummyOperator(task_id='start', dag=dag)
t end = DummyOperator(task id='end', dag=dag)
```

DAG arguments 정의; DAG 옵션 설정



DAG 생성

```
'depends_on_past': False,
'email': ['yje14800@gmail.com'],
'email_on_failure': False,
'email_on_retry': False,
'retries': 1.
'retry_delay': timedelta(minutes=5),
# 'queue': 'bash_queue',
# 'pool': 'backfill',
# 'priority_weight': 10,
# 'end_date': datetime(2016, 1, 1),
# 'wait_for_downstream': False,
# 'dag': dag,
# 'sla': timedelta(hours=2),
# 'execution_timeout': timedelta(seconds=300),
# 'on_failure_callback': some_function,
# 'on_success_callback': some_other_function,
# 'on_retry_callback': another_function,
# 'sla_miss_callback': yet_another_function,
# 'trigger_rule': 'all_success'
```

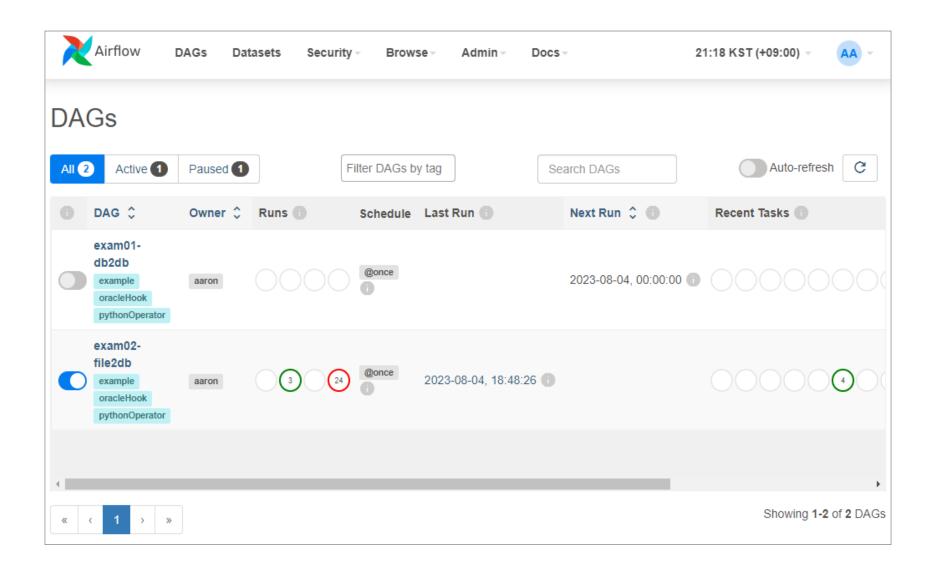
Airflow 샘플

```
t_select_from_source_db = PythonOperator(
    task_id='t_select_from_source_db',
   python_callable=select_from_source_db,
   provide context=True,
    dag=dag,
# TASK : INSERT TARGET DB
t_insert_to_target_db = PythonOperator(
    task_id='t_insert_to_target_db',
   python callable=insert to target db,
   provide_context=True,
   dag=dag,
t_start >> t_select_from_source_db >> t_insert_to_target_db >> t_end
```

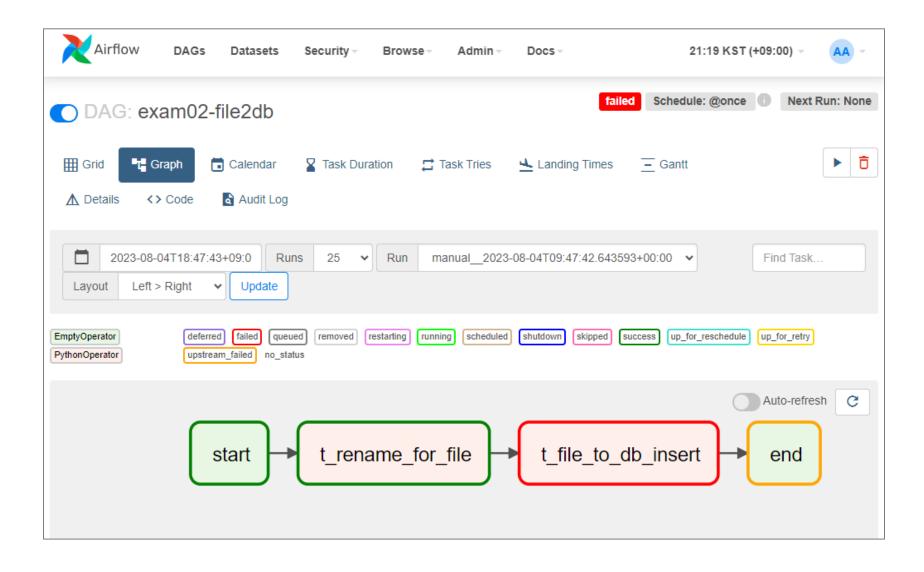
Task 할당; Task = Operator의 인스턴스; Provide_context = True (kwargs – dictionary 형태)

dependencies- 작업 순서 표현 병렬처리 가능: t_start >> [t_1, t_2] >> t_end

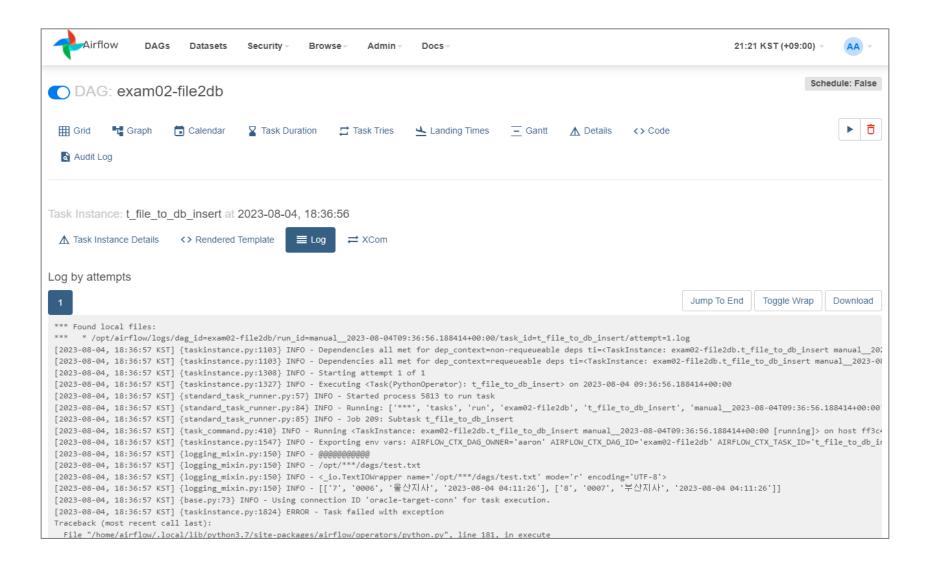
Airflow UI



Airflow UI



Airflow UI



감사합니다.